目标检测整体流程复现

整体步骤

1. 数据集构建和预处理
2. 检测网络结构构建
3. 后处理机制 a. NMS 非极大值抑制 b. 预测标签和真实标签匹配
4. 损失函数设计
5. 训练
6. 测试
7. 整体方法效果评估

数据集构建和预处理

1. pytorch的dataloader构建原理

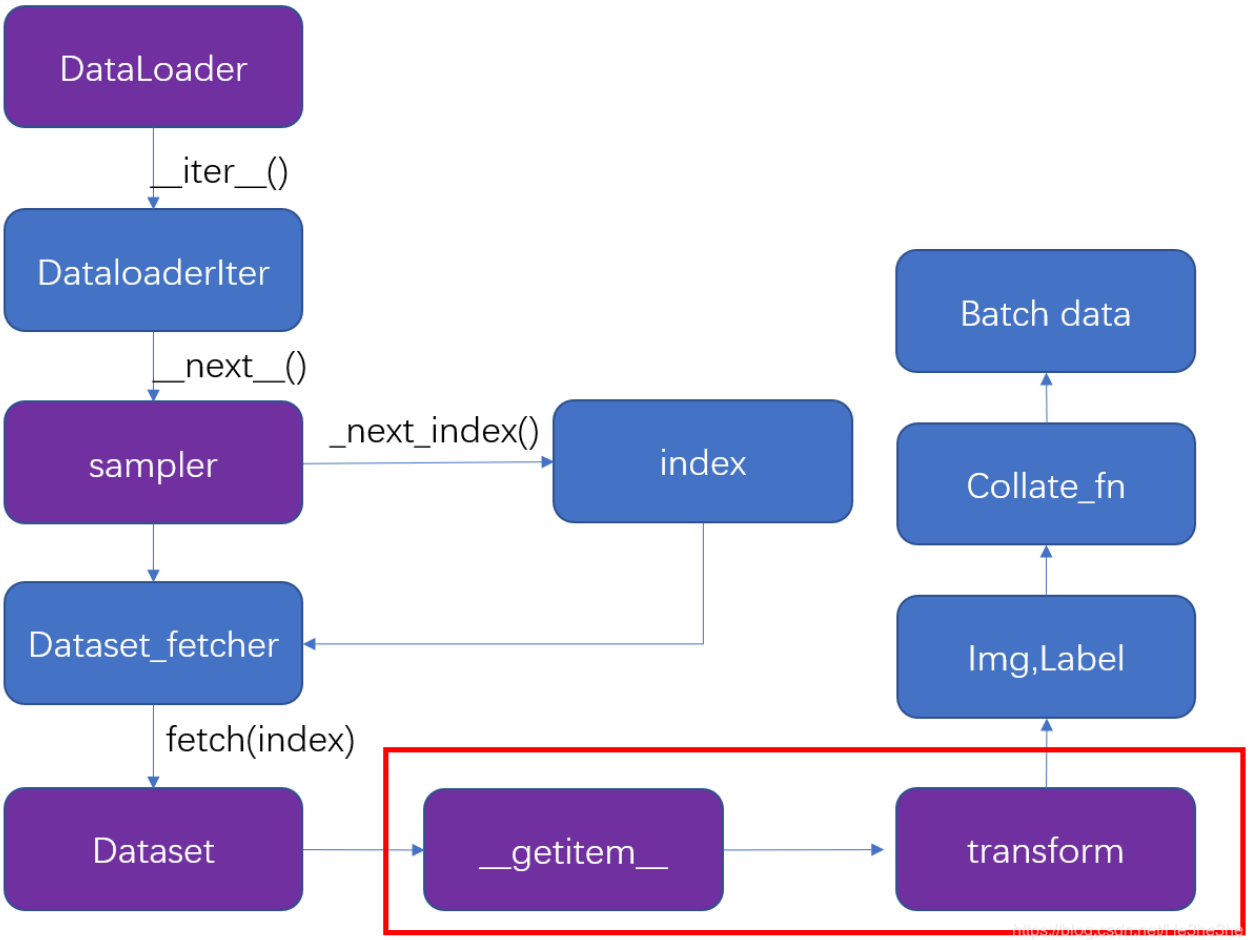

- 需要重写Dataset类的一些方法, **getitem** 会接收一个index参数,这个参数可以是随机的,表示数据集中第几个样本
- dataloader会根据batch_size收集固数量样本组成一个batch,这个batch的样本可以被变换,组成一个batch的操作由函数collate_fn完成,训练时数据增强这一步发生在这里
- 最后返回一个batch的样本和标签
- 过程中问题有每个物体标签的数量不一致,存入和取出对其物体
- 输出示例,标签第一列表示属于一个batch中第几张图片 |images_size|labels_size|label_sample| |---|---|---| |torch.Size([16, 3, 20, 20])|torch.Size([115, 6])|tensor([0.0000, 1.0000, 0.8986, 0.8753,

0.1056, 0.2296])| |torch.Size([16, 3, 20, 20])|torch.Size([127, 6])|tensor([0.0000, 3.0000, 0.5660, 0.8160, 0.0319, 0.0321])|

构建网络

- 简单网络主干由卷积和残差连接组成,最后接了一个输出预测头
- 输出大小分别为 torch.Size([16, 5, 20, 20]) torch.Size([16, 4, 20, 20]), 代表batch_size为16, 输出大小为20x20, 每个位置目标类别概率4个, 盒子数量1个加上置信度
- 导出模型与可视化
- torch.onnx.export(model, x, "model.onnx")

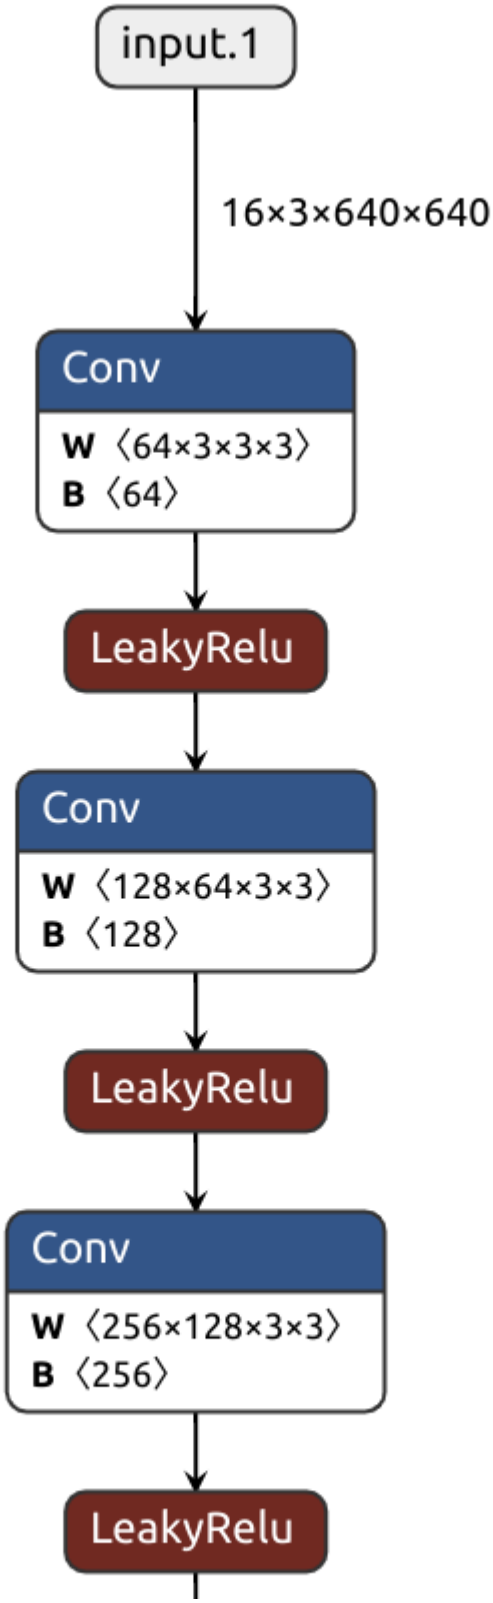

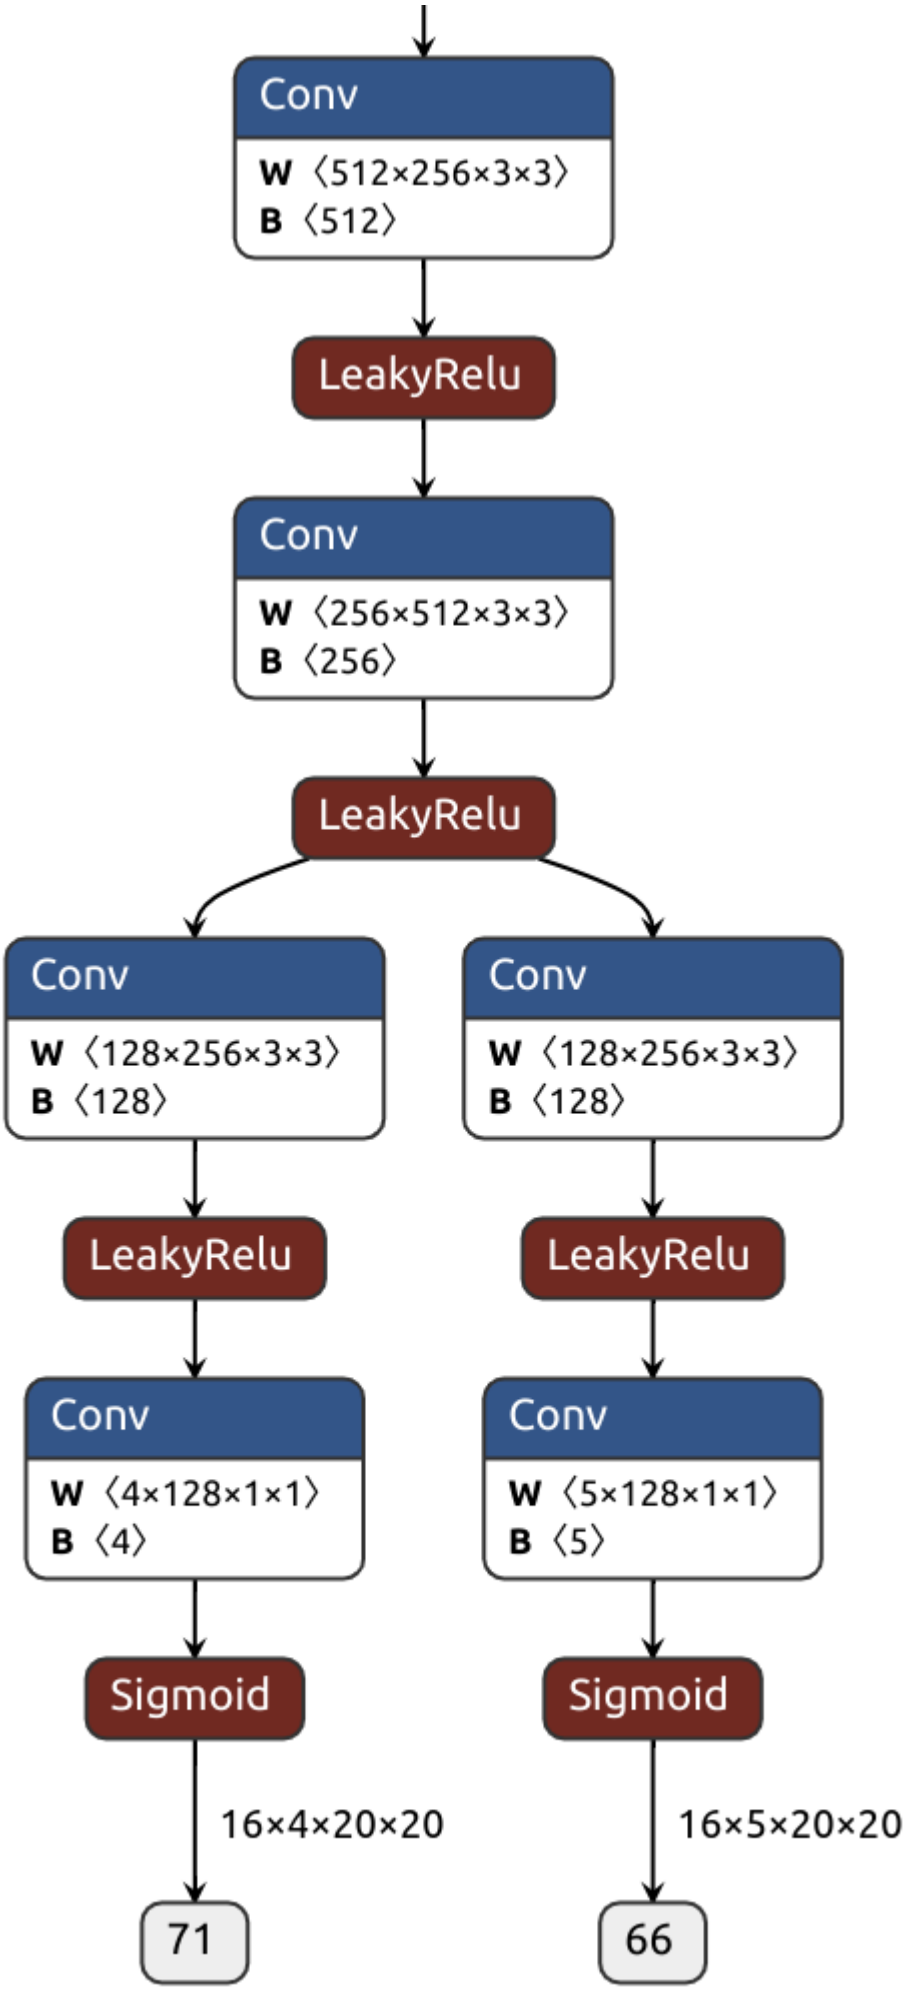
Conv
W 〈512×256×3×3〉
B 〈512〉
LeakyRelu
Conv
W 〈256×512×3×3〉
B 〈256〉
LeakyRelu
Conv
W 〈128×256×3×3〉
B 〈128〉
Conv
W 〈128×256×3×3〉
B 〈128〉
LeakyRelu
LeakyRelu
Conv
W 〈4×128×1×1〉
B 〈4〉
Conv
W 〈5×128×1×1〉
B 〈5〉
Sigmoid
Sigmoid
16×4×20×20
16×5×20×20
71
66

后处理机制

1. 置信度阈值过滤和非极大值抑制, 它能去除重叠检测框,提高检测结果的准确性和减少输出结果的数量,主要流程是

    - 对每张图的盒子预测置信度由高到低把下标排个序,若发现置信度最高的小于给定置信度阈值,终止循环(比如这里是0~399下标排序)
    - 选出第一个也就是置信度最高的,计算他和其他box的iou,将重叠度高的其他box丢弃
    - 重复循环直到所有box都处理完
    - 返回的结果就是所有最好的复测标签下标记
    - NMS伪代码

```
函数 nms(boxes, scores, threshold):
    boxes_to_keep = []
    排序 boxes 按照 scores 的降序顺序
    while boxes 非空:
        取出得分最高的 box
        将其加入 boxes_to_keep
        移除其他与当前 box 有重叠面积大于阈值的 boxes
    返回 boxes_to_keep
```

    - IOU计算: IOU = (Intersection Area) / (Union Area)

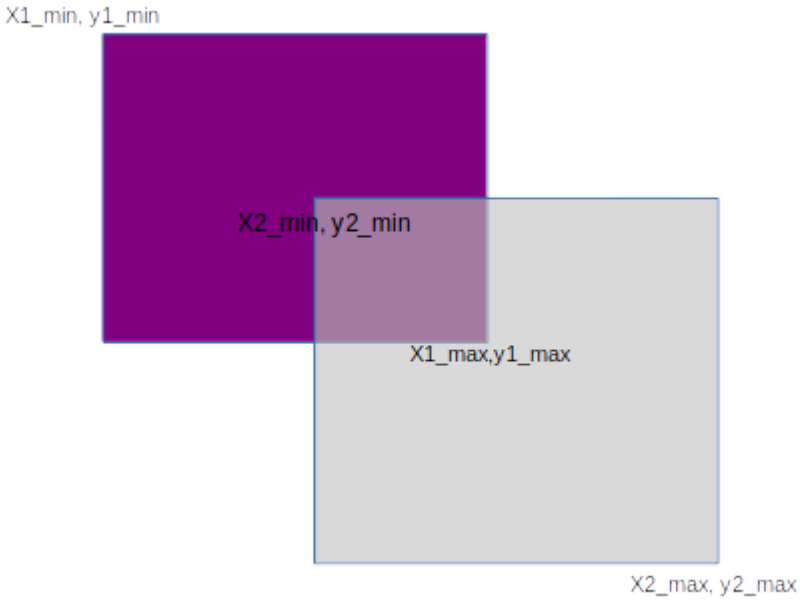


```
area1 = (xmax1 - xmin1) * (ymax1 - ymin1)
area2 = (xmax2 - xmin2) * (ymax2 - ymin2)
area_union = area1 + area2 - area_intersection

iou = area_intersection / (area_union + eps)
```

2. 标签匹配,计算损失的时候需要将输出和真实标签做匹配,这时候就会用到标签匹配

- 基本想法计算每个真实标签和每个预测标签的iou,会得到一个iou矩阵,然后取出每个和每个真实标签对应最大iou的下标,这样就得到了个真实标签一一对应的预测标签 举个例子:

IOU	预测标签1	预测标签2	预测标签3	预测标签4	预测标签400
真实标签1	0.3	0.4	0.5	**0.6**	0.1
真实标签2	0.1	0.6	0.3	0.8	**0.9**
真实标签x	.	.	.	.	.
真实标签n	0.5	0.55	0.1	0.4	**0.6**

- 网上搜的伪代码

```
函数 match_boxes(predicted_boxes, true_boxes, iou_threshold):
    matched_indices = []
    for each predicted_box in predicted_boxes:
        best_iou = 0
        best_true_box_index = -1
        for each true_box in true_boxes:
            计算 predicted_box 和 true_box 的 IoU（交并比）
            如果 IoU 大于等于阈值，并且 IoU 大于当前最佳 IoU：
                更新当前最佳 IoU 和最佳匹配的真实框索引
        如果找到了匹配的真实框索引：
            将该预测框索引和匹配的真实框索引添加到 matched_indices 中
    返回 matched_indices
```

- 但是我这里使用了最早的yolo的思想,没有用到这种一对一匹配思想,yolo的思想是固定位置的输出只负责自己所预测的格子,这种想法实现其来也比较简单

常用损失函数

1. 损失函数在深度学习中非常重要, 选择合适的损失函数对于构建高性能的机器学习模型至关重要, 目标检测常用的有mse和cross_entropy
2. box_loss用MSE损失,每个位置的预测box和真实box的坐标均方差 $$MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$
3. cls_loss用交叉熵损失,交叉熵损失公式为： [J(\theta) = -\frac{1}{m} \sum_{i=1}^{m} \sum_{j=1}^{k} y_j^{(i)} \log(\hat{y}_j^{(i)})]

其中：

- (m) 是样本数量；
- (k) 是类别数量；
- (y_j^{(i)}) 是第 (i) 个样本的真实标签的第 (j) 个元素；
- (\hat{y}_j^{(i)}) 是第 (i) 个样本的模型预测的类别 (j) 的概率。

3. 为了方便,我在代码中代码中都使用类MSE损失

```
    loss_coor = ((gt_boxes[..., :2] - pred_boxes[..., :2]) ** 2 \
                 + (torch.sqrt(pred_boxes[..., 2:4]) -
```

```
torch.sqrt(gt_boxes[..., 2:4])) ** 2).sum(dim=-1)

    loss_confidence = (gt_boxes[..., 4] - pred_boxes[..., 4]) ** 2
    # print(loss_coor.shape)

    loss_class = ((pred_classes - gt_classes) ** 2).sum(dim=-1) * have_obg
    # print(loss_class.shape)

    loss_noOb = (gt_boxes[..., 4] - pred_boxes[..., 4]) ** 2 * no_obj

    loss = (1.0 * loss_coor + loss_confidence + loss_class + 0.1 *
loss_noOb).mean()
```

训练

- env: torch2.1.1+cu121, ubuntu_22.04,
- epochs 10
- batch_size 16
- optiimzer SGD lr=0.01 weight_decay=0.005
- 训练完成 保存模型

测试

- 挑选一张图片进行缩放到640 正则化(和训练时用的一致)
- 输入网络得到预测结果 如输出形状1x20x20x5, 1x20x20x4, yolo认为预测输出的坐标是相对于对应位置的中心偏移, 因此需要对数出进行修正
- 将预测结果进行后处理 将其变成1x400x5, 1x400x4, 并对格子坐标进行处理
    - 执行NMS和置信度阈值筛选
- 可视化最终保留预测框
- 结果如图所示

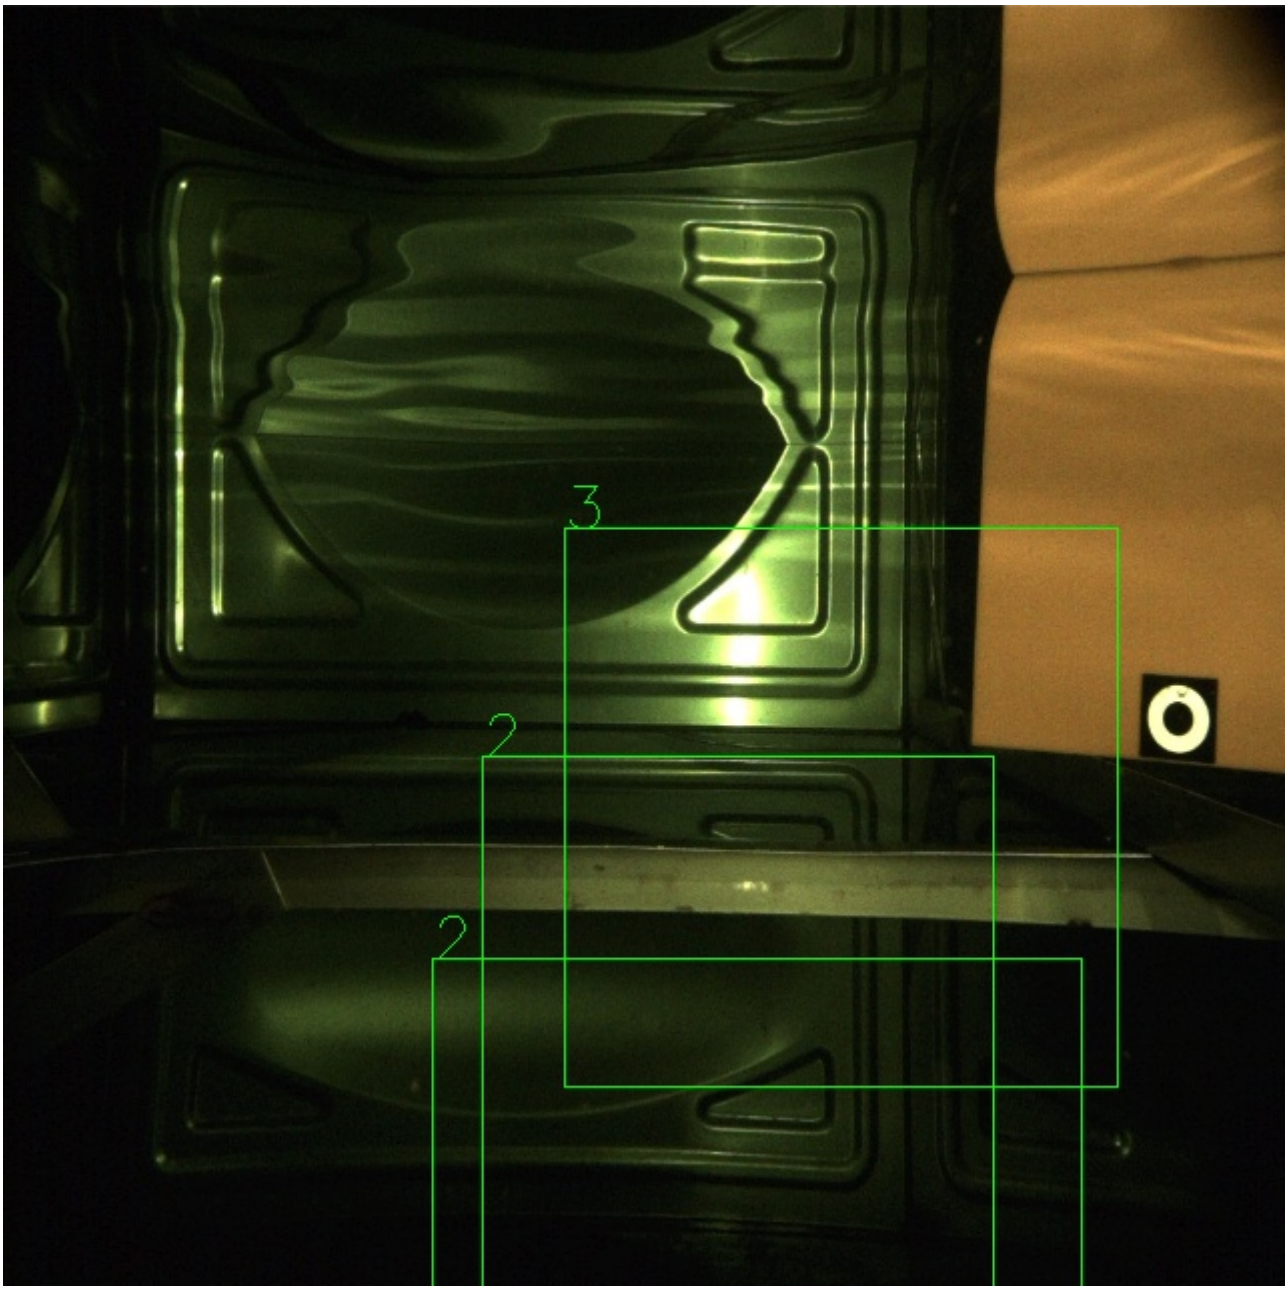

问题

1. 不知道为什么效果不好 看训练的损失是已经下降到很低的程度了 而且在用yolov8框架只训练10轮也有效果, 这里就效果就不好;
2. 使用了很前期yolo思想的grid预置偏移坐标,效果也不是很好,这里我找了一个github上一个开源的从0开始目标检测的代码,准备计较我和他的差别在哪里,找出问题后在把自己的改正.
3. 下一步计划是把这个流程跑通 找出来为什么训练不好的原因 其次试试用检测后的匹配机制替换现在的yolo思想,找找哪里能改进